Calibración de las cuotas de cierre en la Premier League y LaLiga: sensibilidad al método de remoción del margen, diferencias entre ligas y temporadas, y efecto del público local

Informe técnico — Proyecto 2

Estadística Industrial

Facultad de Ingeniería

Ingeniería Industrial

Profesor:

Enrique J. De La Hoz Domínguez

Integrantes:

Andrés Felipe Beleño Mejía

Mauricio Serrano

Carlos Cadena

Universidad del Magdalena

Santa Marta 2026

1. Resumen

Este informe evalúa, de forma retrospectiva, si las probabilidades implícitas en las cuotas de cierre de Bet365 y Pinnacle están calibradas: si los resultados que el mercado valora en un p % ocurren aproximadamente un p % de las veces. El alcance son 2.280 partidos de la Premier League y LaLiga (2022/23–2024/25, Football-Data.co.uk). La pregunta principal es cuánto se aleja la calibración de la diagonal y cuánto de la evidencia de sesgo favorito–longshot depende del método usado para retirar el margen; las secundarias comparan ligas, temporadas y casas, y una cuarta pregunta usa 6.080 partidos (2017/18–2024/25) para estimar el cambio de la ventaja de local en los partidos sin público.

El margen medio fue de 5,45 y 5,54 pp en Bet365 y de 2,79 y 2,75 pp en Pinnacle (Premier y LaLiga). Con el método de potencia, definido como principal antes del análisis, el error de calibración esperado (ECE) fue de 2,6 a 3,0 pp, **menor** que el que produciría un pronóstico perfectamente calibrado con el mismo tamaño de muestra (3,2–3,3 pp; $p \geq 0{,}71$). La pendiente del error (indicador del sesgo favorito–longshot) fue de 0,18 y 0,22 pp por cada 10 pp de probabilidad en la Premier, equivalente a cero con el margen declarado de ±1, y de 1,0 en LaLiga (Bet365: IC 95 % −0,05 a 2,11), un resultado **no concluyente**: el estudio solo tenía 80 % de potencia para pendientes de 1,4–1,6 o más. El hallazgo más sólido es metodológico: el método proporcional añade mecánicamente entre 0,34 y 0,66 pp por 10 pp de pendiente (p de Holm 0,006 en las 4 combinaciones). Las dos casas tuvieron una capacidad predictiva equivalente (diferencias de RPS dentro de ±0,002), mientras que entre ligas y temporadas no se demostró diferencia ni equivalencia. En la Premier, la ventaja de local fue 0,42 puntos por partido menor sin público (IC −0,65 a −0,20), una asociación robusta al ajuste por fuerza de los equipos, a errores estándar por equipo y a una prueba placebo, y no explicada por la regla de cinco sustituciones; en LaLiga la caída (−0,21) no es robusta. El diseño no permite atribuir causalmente todo ese cambio al público.

1.1 Objetivos y trazabilidad

Objetivo general. Evaluar retrospectivamente la calibración de las probabilidades implícitas en las cuotas de cierre de Bet365 y Pinnacle en la Premier League y LaLiga (2022/23–2024/25) y cuantificar en qué medida la evidencia de sesgo favorito–longshot depende del método de remoción del margen.

Objetivos específicos

- **Cuantificar el margen** de Bet365 y Pinnacle en las cuotas de cierre de la Premier League y LaLiga, por liga y temporada, y describir sus diferencias y su evolución entre 2022/23 y 2024/25.
- **Evaluar la calibración** de las probabilidades de victoria local, empate y victoria visitante, obtenidas con cuatro métodos de remoción del margen (proporcional, aditivo,

potencia y Shin), mediante curvas de calibración, el error de calibración esperado (ECE) y su comparación con un pronóstico perfectamente calibrado.

- **Medir el sesgo favorito–longshot** con la pendiente del error y el contraste entre favoritos y longshots, y **cuantificar en qué medida su magnitud y significancia dependen del método** usado para remover el margen.
- **Comparar ligas, temporadas y casas** en calibración, sesgo y capacidad predictiva (RPS), clasificando cada comparación como diferencia, equivalencia o resultado no concluyente mediante intervalos de confianza, pruebas de equivalencia y el efecto mínimo detectable.
- **Estimar el cambio en la ventaja de local asociado a los partidos sin público** en la pandemia (2017/18–2024/25), ajustado por la fuerza de los equipos. Examinar además los canales arbitral y deportivo, someter a prueba explicaciones alternativas (tendencias temporales y regla de cinco sustituciones) y evaluar si las cuotas de cierre se ajustaron a ese cambio.

Tabla 1. Matriz de trazabilidad entre objetivos, métodos y resultados.

Objetivo	Pregunta	Métodos	Resultado	Evidencia alcanzada
OE1 · Margen	Contexto	Media e IC por bloques	5.1, Tabla 4	Descriptiva, precisa
OE2 · Calibración y sesgo	Principal	Curvas, ECE frente a su nulo, pendiente, extremos (25 umbrales), regresión logística	5.2–5.4, Tablas 5–6, Figuras 2–3	Premier: criterio cumplido. LaLiga: no concluyente. Efecto del método: sólido
OE3 · Ligas, temporadas y casas	Secundarias 1 y 2	Contrastes pareados, Holm, equivalencia (TOST)	5.5, Tabla 7	Casas: equivalentes. Ligas y temporadas: no concluyente
OE4 · Público local	Secundaria 3	Contrastes por periodo, modelo con fuerza, placebo, sustituciones, aforo	5.6, Tabla 8, Figura 4	Premier: asociación robusta. LaLiga: débil. Causalidad: no identificada

2. Marco conceptual

2.1 Cuota, probabilidad implícita y margen

Una cuota decimal o paga o unidades por unidad apostada si el evento ocurre; su inverso, $1/o$, es la **probabilidad implícita bruta**. En un partido con tres resultados, $S = 1/o(H) + 1/o(D) + 1/o(A) > 1$: el exceso es el **margen** u *overround*, reportado como $100 \cdot (S - 1)$ pp. Por eso las probabilidades brutas no se comparan con frecuencias (suman más de 100 %), y por eso el valor esperado de una apuesta es negativo en promedio: la casa paga como si las probabilidades sumaran $S > 1$.

2.2 Calibración, resolución y eficiencia

Un pronóstico está **calibrado** si, entre los eventos a los que asigna probabilidad p, la frecuencia observada es p. La **resolución** es la capacidad de asignar probabilidades distintas a eventos con frecuencias distintas. El puntaje de Brier se descompone como $BS = REL - RES + UNC$ (Murphy, 1973): confiabilidad (error de calibración), resolución e incertidumbre del fenómeno. Estas propiedades son distintas de la **eficiencia informativa** (que la cuota incorpore toda la información pública disponible) y de la **eficiencia económica** (que no exista una regla de apuesta con valor esperado positivo después del margen). La calibración es necesaria pero no suficiente para ambas:

probar eficiencia exigiría mostrar que ninguna información adicional predice los errores de la cuota, algo que este estudio no hace. Aquí solo se evalúan calibración y capacidad predictiva, siguiendo la tradición de tratar las cuotas como pronósticos (Forrest, Goddard y Simmons, 2005).

2.3 Sesgo favorito–longshot

El **sesgo favorito–longshot** (FLB) es la regularidad documentada desde Griffith (1949) según la cual los resultados poco probables están sobrevalorados y los favoritos infravalorados. En calibración aparece como una pendiente positiva del error (observado − pronosticado) frente a la probabilidad. Su origen se atribuye a preferencias por el riesgo, a percepciones erróneas (Snowberg y Wolfers, 2010) o a precios fijados deliberadamente por las casas (Levitt, 2004); este estudio no distingue entre esas explicaciones.

2.4 Remoción del margen: supuestos de cada método

Retirar el margen exige suponer cómo lo reparte la casa entre los resultados. Cada método encarna un supuesto distinto (Tabla 2), y ese supuesto, no los datos, determina parte del sesgo que luego se mide.

Tabla 2. Métodos de remoción del margen y sus supuestos.

Método	Fórmula	Supuesto sobre el reparto del margen	Limitación principal
Proporcional	$q_i = p_i / S$	Misma recarga relativa en todos los resultados	Si la casa recarga más los longshots, deja margen en las probabilidades bajas y fabrica un FLB aparente
Aditivo	$q_i = p_i - (S - 1)/3$	Misma recarga absoluta por resultado	Puede dar probabilidades negativas en longshots extremos (no ocurrió en estos datos)
Potencia	$q_i = p_i^k$, $\Sigma\, q_i = 1$	Recarga relativa mayor cuanto menor es la probabilidad	Forma funcional sin modelo de comportamiento; un parámetro por partido (k medio 1,06 en Bet365 y 1,03 en Pinnacle)
Shin	$q_i(z)$, $\Sigma\, q_i = 1$	La casa se protege de una fracción z de dinero informado (Shin, 1991, 1993)	Derivado para una casa que fija precios frente a insiders; en mercados de cierre líquidos, z (0,028 y 0,014 aquí) refleja la estructura del margen más que información privilegiada real

Por qué potencia como método principal. Clarke, Kovalchik e Ingram (2017) hallaron que el método de potencia producía probabilidades más precisas que el multiplicativo en tres bases deportivas; Štrumbelj (2014) encontró que Shin superaba a la normalización básica (no evaluó potencia) y que esa ventaja disminuye a medida que el mercado es más grande. Ambos métodos cargan más margen sobre los longshots, y el de potencia siempre produce probabilidades válidas con un solo parámetro. Que esa evidencia se transfiera a las cuotas de cierre de la Premier y LaLiga **no se supone**: se contrasta en la Sección 5.4 con puntuaciones propias. La elección es una especificación previa, no una afirmación de que potencia represente las probabilidades «verdaderas»; la liquidez de una liga tampoco demuestra por sí sola que un método sea superior.

2.5 Ventaja de local: esquema causal

La ventaja de local puede deberse al viaje, a la familiaridad con el estadio, a la presión del público sobre el árbitro o a su efecto sobre el rendimiento. Los partidos sin público de 2020–2021 permiten observar qué pasa cuando falta uno de esos factores, pero el mismo periodo cambió otras condiciones (calendario comprimido, regla de cinco sustituciones, contagios en las plantillas). La

Figura 1 resume el esquema conceptual que guía el análisis. Se distinguen tres estimandos: (i) el **cambio observado** de la ventaja de local entre periodos; (ii) el **cambio ajustado** por la fuerza de cada equipo en cada temporada; y (iii) el **efecto causal del público**, que solo coincidiría con (ii) si ningún otro cambio del periodo afectara la ventaja de local. El diseño identifica (i) y (ii); para (iii) solo puede someter a prueba confusores concretos (Sección 4.7). McCarrick et al. (2021) observaron en 11 ligas una caída de 0,39 a 0,22 puntos por partido, y Bryson et al. (2021), cerca de un tercio menos de amarillas al visitante.

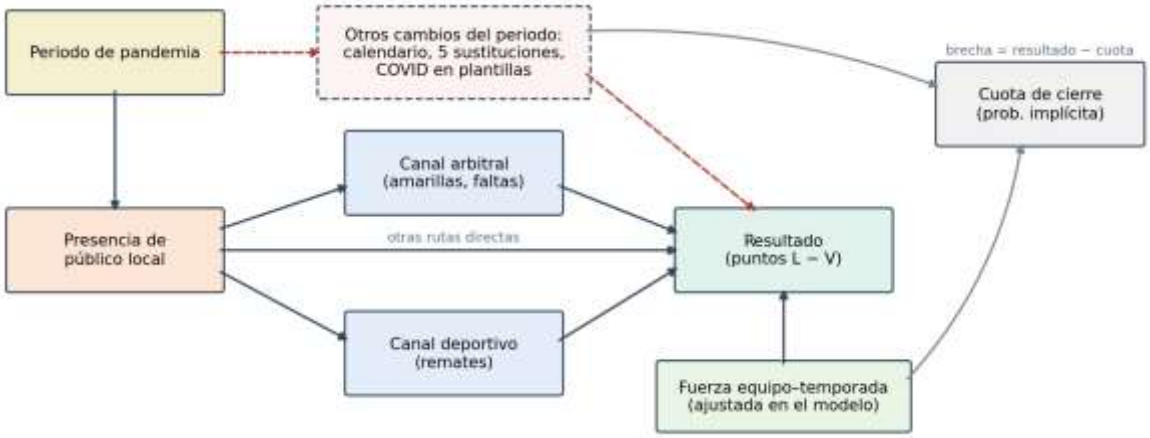


Figura 1. Esquema causal hipotético del efecto del público sobre el resultado. Flechas continuas: canales del efecto; rojas discontinuas: rutas de confusión que el diseño no bloquea; grises: información que usa el mercado. No es un mecanismo demostrado por los datos.

3. Datos

Fuente y procedencia. Archivos CSV por liga y temporada de Football-Data.co.uk (https://www.football-data.co.uk/mmz4281/<temporada>/E0.csv y SP1.csv). La fecha de obtención registrada es la marca de tiempo de los archivos entregados por el equipo: 29/09/2026 para 2022/23–2024/25 y 01/10/2026 para 2017/18–2021/22. Para cada archivo se guardaron la URL de origen (deducida de la liga y la temporada), el tamaño y la huella SHA-256 (Anexo D); el código se detiene si un archivo no coincide con su huella, lo que garantiza que cualquier reproducción usa la misma versión.

Ligas, temporadas y operadores. La calibración usa las temporadas completas 2022/23, 2023/24 y 2024/25; la pregunta del público usa 2017/18 a 2024/25. Se incluyeron **Bet365** (mercado masivo, margen alto) y **Pinnacle** (margen bajo, referencia de mercado), siempre con **cuotas de cierre** (B365CH/CD/CA y PSCH/CD/CA). Las demás casas, los promedios y máximos de mercado y las cuotas previas al cierre se excluyeron para no mezclar momentos de información ni duplicar operadores. **Advertencia de Pinnacle:** Football-Data indica que sus cuotas quedaron desactualizadas desde el 23/07/2025; por eso la ventana termina en 2024/25. La temporada 2026/27 se excluyó por incompleta.

Tabla 3. Inventario de cobertura de cuotas de cierre válidas.

Análisis	Liga	Temporadas	Partidos	Bet365	Pinnacle	Exclusiones
Calibración	Premier League	2022/23–2024/25	1.140	1.140 (100 %)	1.140 (100 %)	Ninguna
Calibración	LaLiga	2022/23–2024/25	1.140	1.140 (100 %)	1.140 (100 %)	Ninguna
Público local	Premier League	2017/18–2024/25	3.040	2.280 (75 %)	3.040 (100 %)	Bet365 sin cierre antes de 2019/20; 65 partidos con aforo mínimo
Público local	LaLiga	2017/18–2024/25	3.040	2.280 (75 %)	3.039 (99,97 %)	Ídem; 1 partido sin cierre de Pinnacle; 20 con aforo mínimo y 68 con aforo parcial

Fuente: elaboración propia con datos de Football-Data.co.uk; detalle por temporada en outputs/tables/inventario_cobertura.csv.

Validaciones. En cada archivo se comprobó que las fechas se leyeran como dd/mm/aaaa y quedaran dentro de su temporada, que el resultado coincidiera con los goles, que no hubiera partidos duplicados, que cada temporada tuviera 380 partidos y 20 equipos con 38 partidos cada uno, que ninguna cuota fuera ≤ 1 ni ninguna suma $S \leq 1$, y se marcaron (sin eliminarlos) los márgenes atípicos por la regla de Tukey. No se excluyó ningún partido de la calibración ni se imputó ninguna cuota.

Clasificación por aforo. Football-Data no informa la asistencia de cada partido, por lo que los periodos se definieron por fecha: con público hasta el 09/03/2020; sin público hasta el 31/07/2021; **aforo mínimo** cuando las autoridades permitieron asistencia restringida (Premier 02–26/12/2020 y 18–23/05/2021; LaLiga 16–23/05/2021); y **aforo parcial** en LaLiga entre el 01/08 y el 30/09/2021, cuando los estadios reabrieron con límites de capacidad. Como esa clasificación por fecha puede incluir partidos sin público en regiones con restricciones, estos 153 partidos se excluyen del contraste principal y se reportan por separado (Sección 5.6).

4. Metodología

4.1 Margen y probabilidades ajustadas

Para cada partido y casa se calculó $p_i = 1/o_i$, $S = \Sigma\, p_i$ y el margen $100\cdot(S - 1)$. Las probabilidades ajustadas se obtuvieron con los cuatro métodos de la Tabla 2 (k y z se resuelven numéricamente para que $\Sigma\, q_i = 1$). El método de potencia es el principal; los otros tres son sensibilidad.

4.2 Calibración

Para cada liga, casa, método y resultado se formaron 10 grupos de igual frecuencia (≈ 114 partidos) y se comparó la probabilidad media pronosticada con la frecuencia observada (desviación en pp, con IC de Wilson y por bloques). El **ECE** es el promedio ponderado de |desviación|. Como el ECE es positivo aun con un pronóstico perfecto, se comparó con su **distribución bajo calibración perfecta**: se simularon 2.000 temporadas en las que cada resultado ocurre exactamente con la probabilidad de la cuota, y se calculó cuántas producen un ECE mayor que el observado (con 5, 10, 15 y 20 grupos). Como medidas que no dependen de agrupar se usaron la regresión logística de calibración $\text{logit}(y) = \alpha + \beta\cdot\text{logit}(q)$ (calibración perfecta: $\alpha = 0$, $\beta = 1$; errores agrupados por partido), la prueba de Spiegelhalter y una **curva continua** del error estimada con un núcleo gaussiano de 4 pp de ancho y banda por bloques.

4.3 Sesgo favorito–longshot

La medida principal es la **pendiente del error**: la regresión de $100 \cdot (y - q)$ sobre $10 \cdot q$, apilando los tres resultados; el coeficiente indica cuántos pp aumenta el error por cada 10 pp de probabilidad. La complementaria es el **contraste de extremos**: error medio de los eventos con $q > 60$ % menos el de los eventos con $q < 20$ %, con pertenencia fijada por el método proporcional para comparar los mismos eventos entre métodos. Como la elección de umbrales es arbitraria, el contraste se calculó para una **matriz de 25 pares** (inferior 10–30 %, superior 50–70 %), con Holm sobre las 25 especificaciones.

4.4 Puntuaciones y descomposición

La capacidad predictiva se midió con Brier multiclase, log loss y **Ranked Probability Score** (RPS), comparados con la referencia uniforme y con la frecuencia histórica dejando la temporada evaluada fuera ($RPSS = 1 - RPS/RPS_ref$). La descomposición de Murphy se calculó por resultado con 10 grupos de igual frecuencia (sensibilidad: 5, 15 y 20), y su REL se comparó con su valor esperado bajo calibración perfecta. Las diferencias pareadas de RPS y log loss entre métodos permiten contrastar cuál produce mejores pronósticos en estos mercados.

4.5 Inferencia y dependencia

Los intervalos se obtuvieron con **bootstrap circular de bloques** de 20 partidos consecutivos dentro de cada liga–temporada (2.000 réplicas, semilla 20261001). El remuestreo se hace sobre partidos completos: las cuotas, los tres resultados y todas las variables de un partido viajan juntos, y en los contrastes pareados (entre métodos o casas) se usan los mismos pesos para las dos condiciones. La elección del bloque se justificó con datos: (i) autocorrelación y prueba de Ljung–Box de las contribuciones de cada partido a la pendiente y al RPS; (ii) longitud de bloque óptima de Politis y White (2004; corrección de Patton et al., 2009); (iii) sensibilidad con bloques de 1, 10 y 40 y con remuestreo de **semanas completas** (≈ jornadas). La dependencia entre partidos no consecutivos de un mismo equipo se evaluó con (iv) errores estándar robustos a dependencia diádica, que suman las covarianzas de todos los pares de partidos que comparten un equipo (Aronow, Samii y Assenova, 2015), y (v) una prueba de dispersión por equipo–temporada: si algún equipo estuviera sistemáticamente mal valorado, sus victorias se alejarían de las esperadas más de lo que permite el azar.

Comparaciones múltiples. Las familias de Holm se definieron por la pregunta, no por los resultados: una familia por pregunta y métrica (por ejemplo, las 16 pendientes de la pregunta principal: 2 ligas × 2 casas × 4 métodos). Los análisis por temporada se tratan como exploratorios y los de bloques, umbrales y métodos como sensibilidad, cada uno en su propia familia. El Anexo B lista las 50 familias con sus 988 hipótesis, sus p mínimos y cuántas son significativas antes y después del ajuste. Con 2.000 réplicas, el menor p bootstrap posible es 1/2.001.

4.6 Potencia y equivalencia

Para no confundir «no significativo» con «no hay efecto» se calculó el **efecto mínimo detectable** (EMD) con 80 % de potencia, $EMD = (z_{0,975} + z_{0,80}) \cdot EE \approx 2{,}80 \cdot EE$, usando el mayor error estándar

entre los esquemas de remuestreo (y la versión con Holm). Para afirmar ausencia de diferencias se usó una **prueba de equivalencia** (TOST, Lakens, 2017): hay equivalencia si el IC 90 % queda dentro de ±Δ. Márgenes: Δ = 1 pp por 10 pp para pendientes (un sesgo menor implica menos de 5 pp de diferencia de error entre un evento de 20 % y uno de 70 %, inferior al margen medio de Bet365 y, por tanto, no aprovechable); Δ = 0,002 en RPS (≈ 5 % de la mejora de las cuotas sobre la referencia histórica); Δ = 0,02 en RPSS. Estos márgenes se fijaron durante la revisión del informe, después de conocer las estimaciones; por eso se aplican a **todas** las comparaciones, sin selección, y cada una se clasifica como equivalente, diferente o no concluyente.

4.7 Pregunta del público local

Medidas: diferencia de puntos local − visitante, % de victorias locales, diferencias de goles y remates, amarillas y faltas del visitante − local (canal arbitral), probabilidad implícita de victoria local (potencia) y brecha observada − implícita. Además del contraste sin público − con público se estimó un modelo de mínimos cuadrados con efectos de fuerza equipo–temporada. Para los confusores de la Figura 1 se hicieron cuatro pruebas: (a) **placebo temporal**, que repite el contraste con todas las ventanas de partidos consecutivos con público del mismo tamaño que el periodo cerrado (desplazadas de 5 en 5); (b) **regla de sustituciones**, aprovechando que la Premier jugó 2020/21 a puerta cerrada con tres cambios y adoptó cinco desde 2022/23 con público (Sky Sports, 2022), mientras LaLiga usó cinco desde la reanudación de 2020 (Goal, s. f.); (c) **dosis**, comparando partidos con aforo mínimo y parcial; y (d) errores estándar diádicos por equipo–temporada. La respuesta del mercado se evaluó con la brecha en la primera y la segunda mitad del periodo cerrado.

5. Resultados

5.1 Margen

Bet365 cobra aproximadamente el doble que Pinnacle (Tabla 4); la diferencia pareada fue de −2,66 pp en la Premier (IC −2,72 a −2,60). El margen de Bet365 se mantuvo entre 5,4 y 5,7 pp, mientras que el de Pinnacle subió de 2,4–2,5 pp en 2022/23 a 3,0 pp en 2024/25 en ambas ligas.

Tabla 4. Margen medio (pp) por casa, liga y temporada, con IC 95 %.

Liga	Casa	2022/23	2023/24	2024/25	Total
Premier League	Bet365	5,40 (5,33–5,49)	5,39 (5,32–5,46)	5,55 (5,47–5,63)	5,45 (5,41–5,49)
Premier League	Pinnacle	2,46 (2,41–2,51)	2,93 (2,84–3,00)	2,99 (2,96–3,03)	2,79 (2,76–2,83)
LaLiga	Bet365	5,59 (5,52–5,66)	5,39 (5,31–5,47)	5,65 (5,60–5,71)	5,54 (5,50–5,59)
LaLiga	Pinnacle	2,41 (2,37–2,45)	2,84 (2,73–2,93)	3,00 (2,95–3,04)	2,75 (2,71–2,79)

5.2 Calibración

El ECE con potencia fue de 2,59 a 2,98 pp, pero ese valor no indica por sí solo descalibración: un pronóstico perfectamente calibrado, con 1.140 partidos, tendría un ECE medio de 3,2–3,3 pp (Tabla 5). En las 64 combinaciones evaluadas (2 ligas × 2 casas × 4 métodos × 4 números de grupos), el ECE observado fue menor que el esperado bajo calibración perfecta en 52 y ninguna lo superó de forma significativa (p mínimo 0,16); lo mismo ocurrió con la confiabilidad (REL) en

56 de 64. Es decir, las desviaciones por intervalo son del tamaño del ruido muestral: con potencia, 5 de los 120 intervalos (4,2 %) tienen un IC que excluye cero, la proporción esperada por azar. La regresión logística da $\beta \approx 1{,}02$–$1{,}03$ en la Premier (IC con 1) y 1,13–1,14 en LaLiga (IC 0,99 a 1,28), lo que vuelve a señalar LaLiga.

Tabla 5. Calibración y capacidad predictiva con el método de potencia (1.140 partidos por fila).

Liga	Casa	ECE (pp)	ECE bajo calibración perfecta: media (p95)	p	Pendiente, pp/10 pp (IC 95 %)	β logística (IC 95 %)	RPSS	REL (nulo)	RES
Premier League	Bet365	2,59	3,21 (4,05)	0,90	0,18 (−0,80 a 1,05)	1,02 (0,90 a 1,15)	0,181	0,0031 (0,0049)	0,085
Premier League	Pinnacle	2,62	3,21 (4,04)	0,89	0,22 (−0,75 a 1,10)	1,03 (0,90 a 1,16)	0,181	0,0039 (0,0049)	0,086
LaLiga	Bet365	2,98	3,28 (4,10)	0,71	1,00 (−0,05 a 2,11)	1,13 (0,99 a 1,28)	0,162	0,0040 (0,0051)	0,079
LaLiga	Pinnacle	2,87	3,29 (4,15)	0,82	1,02 (−0,05 a 2,14)	1,14 (0,99 a 1,28)	0,161	0,0038 (0,0052)	0,077

p: proporción de simulaciones con calibración perfecta cuyo ECE supera el observado. RPSS frente a la frecuencia histórica dejando una temporada fuera. REL y RES: confiabilidad y resolución (Murphy); entre paréntesis, REL esperado bajo calibración perfecta. Con 5 a 20 grupos, REL varía entre 0,0015 y 0,0088 y RES entre 0,074 y 0,093: ambos dependen del agrupamiento, pero REL nunca supera el percentil 95 de su distribución bajo calibración perfecta.

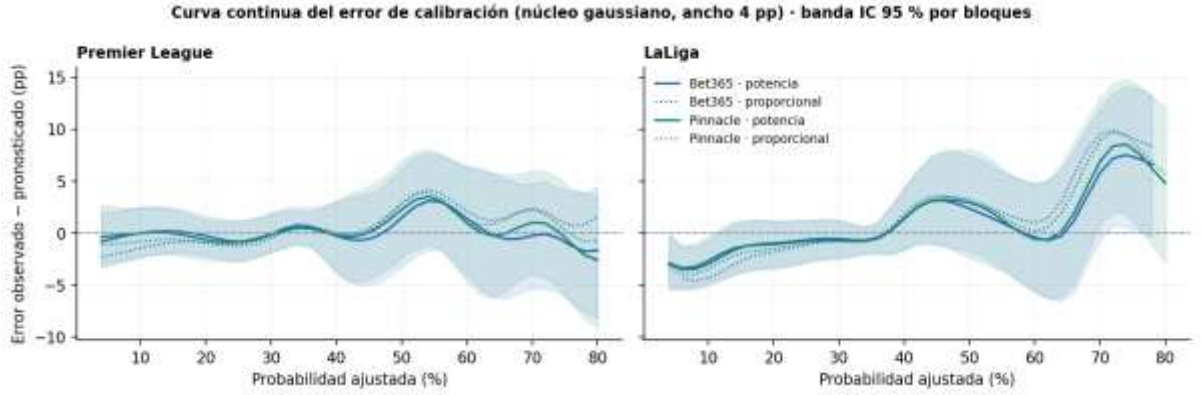


Figura 2. Error de calibración como función continua de la probabilidad (núcleo gaussiano de 4 pp, tres resultados apilados), con banda IC 95 % por bloques. Líneas punteadas: método proporcional.

La curva continua (Figura 2) muestra el patrón que resumen las pendientes: en la Premier el error oscila alrededor de cero en todo el rango; en LaLiga los eventos con probabilidad de 4–12 % ocurren entre 2 y 3,5 pp menos de lo pronosticado y los de 70–76 % entre 6 y 8,5 pp más. Las bandas son puntuales (no simultáneas) y amplias en los extremos, donde hay pocos eventos.

5.3 Sesgo favorito–longshot y sensibilidad al método

El método cambia la evidencia de sesgo (Tabla 6). Con el proporcional, LaLiga muestra pendientes cuyo IC excluye cero (1,66 y 1,37); con potencia y aditivo, no. La diferencia pareada potencia − proporcional es negativa en las 4 combinaciones: −0,62 y −0,66 pp por 10 pp en Bet365 y −0,34 y −0,36 en Pinnacle (EE ≤ 0,03; p de Holm 0,006). Es mayor en Bet365 porque tiene más margen que repartir. Esta diferencia mide el efecto del supuesto de reparto, no el reparto real: con las mismas cuotas y resultados, lo único que cambia es la regla con que se retira el margen.

Tabla 6. Pendiente del error (pp por 10 pp) según el método, con IC 95 % por bloques.

Liga	Casa	Proporcional	Potencia	Aditivo	Shin
Premier League	Bet365	0,79 [−0,24; 1,72]	0,18 [−0,80; 1,05]	0,23 [−0,75; 1,11]	0,37 [−0,62; 1,26]
Premier League	Pinnacle	0,56 [−0,43; 1,48]	0,22 [−0,75; 1,10]	0,25 [−0,72; 1,13]	0,32 [−0,65; 1,22]
LaLiga	Bet365	1,66 [0,55; 2,83]	1,00 [−0,05; 2,11]	1,04 [−0,01; 2,16]	1,20 [0,13; 2,32]
LaLiga	Pinnacle	1,37 [0,27; 2,53]	1,02 [−0,05; 2,14]	1,04 [−0,03; 2,16]	1,12 [0,04; 2,25]

Robustez a los umbrales. En LaLiga, los 25 pares de umbrales dan un contraste positivo con potencia (3,9 a 10,8 pp en Bet365 y 3,3 a 8,9 en Pinnacle), pero el IC excluye cero solo en 9 y 7 de las 25 especificaciones, sobre todo cuando el umbral de favoritos es 65 %, y **ninguna** sobrevive a Holm dentro de la matriz (Figura 3). En la Premier ninguna especificación es significativa (−1,1 a 2,0 pp). La conclusión defendible es que la **dirección** del sesgo residual en LaLiga es estable, pero su **significancia** depende de la especificación; el valor de 10,8 pp con umbrales 15/65 de la versión anterior del informe es el máximo de la matriz y no debe leerse aisladamente: evaluado solo, en su propia familia de 16 contrastes, superaba a Holm (p = 0,03), lo que ilustra el riesgo de elegir un único par de umbrales.



Figura 3. Contraste de extremos (pp) con el método de potencia para 25 pares de umbrales. * IC 95 % por bloques excluye cero sin ajustar; ninguna celda es significativa tras Holm sobre las 25 especificaciones.

5.4 Desempeño predictivo de los métodos

Con puntuaciones propias, potencia nunca fue peor que los otros métodos, pero las diferencias son mínimas. En LaLiga–Bet365 mejoró el log loss frente al proporcional en −0,0021 (IC −0,0039 a −0,0005), sin significancia tras Holm (p = 0,26); frente a Shin y aditivo las diferencias fueron del orden de 10^{-4}. En la Premier ninguna diferencia excluye cero. Coincide con Štrumbelj (2014): en mercados grandes las ventajas entre métodos se vuelven pequeñas. Los datos no permiten afirmar que un método represente mejor las probabilidades justas; solo que la elección de potencia no empeora los pronósticos.

5.5 Ligas, temporadas y casas: diferencia, equivalencia o indeterminación

La Tabla 7 clasifica todas las comparaciones de las preguntas secundarias. Las casas son **equivalentes** en capacidad predictiva en las 8 comparaciones (IC 90 % dentro de ±0,002 de RPS): una vez retirado el margen, Bet365 y Pinnacle pronostican igual pese a cobrar márgenes distintos. Para ligas y temporadas, en cambio, **no se demuestra ni diferencia ni equivalencia**: la pendiente

de LaLiga supera a la de la Premier en 0,82 pp por 10 pp (IC −0,53 a 2,33), un intervalo compatible tanto con ninguna diferencia como con una de más de 2 pp. El EMD de esa diferencia es 2,05 pp por 10 pp (2,62 con Holm), muy por encima de lo estimado. Ocho diferencias de RPSS entre 2022/23 y 2023/24 tuvieron un IC sin ajustar que excluye cero (p entre 0,047 y 0,058), pero ninguna sobrevive a Holm.

Tabla 7. Clasificación de las comparaciones secundarias (método de potencia y sensibilidad; IC por bloques).

Familia	Margen Δ	Comparaciones	Equivalentes	Diferentes	No concluyentes
Calibración: pendiente del error = 0	1,00	16	4	4	8
Casas: RPS Pinnacle − Bet365	0,002	8	8	0	0
Ligas: pendiente LaLiga − Premier	1,00	8	0	0	8
Ligas: RPSS LaLiga − Premier	0,02	8	0	0	8
Temporadas: pendiente	1,00	32	0	0	32
Temporadas: RPSS	0,02	32	0	8	24

Equivalente: IC 90 % dentro de ±Δ. Diferente: IC 95 % sin ajustar excluye cero. La primera fila incluye los 4 métodos: con potencia, las pendientes de la Premier son equivalentes a cero y las de LaLiga no concluyentes; las 4 «diferentes» son proporcional y Shin en LaLiga.

Potencia y dependencia. El EMD de la pendiente fue de 1,37 pp por 10 pp en la Premier y de 1,55–1,57 en LaLiga (1,85–2,13 con Holm); el del contraste de extremos, de 9,4 a 10,5 pp. Por tanto, el estudio podía detectar un FLB fuerte, pero no uno como el estimado en LaLiga. En cuanto a la dependencia, ninguna de las 24 series (6 liga–temporadas × 2 casas × 2 medidas) mostró autocorrelación significativa (Ljung–Box, 20 rezagos) y la longitud de bloque óptima de Politis–White fue de 1,4 partidos (máximo 2,2); los errores estándar con bloques de 1, 10 y 40 y con semanas completas variaron entre 0,85 y 1,21 veces los de bloques de 20 (Anexo C). Con potencia ninguna conclusión cambia; en cambio, el contraste 20/60 de LaLiga–Pinnacle excluye cero con remuestreo independiente o con bloques de 40, y con el método proporcional la pendiente de LaLiga–Bet365 supera a Holm con remuestreo independiente: otra señal de que la evidencia sobre LaLiga es frágil. La prueba de dispersión por equipo no detectó equipos mal valorados (χ^2 con 60 g.l., p = 0,49–0,61). Los errores diádicos fueron 0,85–0,88 veces los agrupados por partido en la Premier y 0,42–0,44 en LaLiga; con ellos la pendiente de LaLiga sería significativa, pero no se adoptan como inferencia principal porque con 60 conglomerados este estimador es inestable y es el menos conservador de los evaluados (Cameron y Miller, 2015).

5.6 Público local

En la Premier la ventaja de local fue de 0,40 puntos por partido con público y de −0,01 sin público (Tabla 8). El cambio, −0,42 (IC −0,65 a −0,20; p de Holm 0,005), se mantiene ajustando por la fuerza de los equipos (−0,40), con el esquema de remuestreo más conservador (IC −0,69 a −0,13) y con errores diádicos por equipo (ajustado: IC −0,74 a −0,05). En LaLiga la ventaja bajó de 0,53 a 0,32 (−0,21; IC −0,42 a −0,004), pero ese resultado no es robusto: no sobrevive a Holm (p = 0,24) y su IC incluye cero con remuestreo independiente; su EMD (0,30–0,35 puntos) supera la caída estimada. La diferencia entre ligas no es significativa (−0,19; IC −0,47 a 0,11).

Tabla 8. Cambio a puerta cerrada respecto de los partidos con público (sin público − con público).

Medida	Unidad	Premier	IC 95 %	p Holm	LaLiga	IC 95 %	p Holm
Victorias locales	%	−6,35	−10,26 a −2,57	0,007	−4,77	−8,29 a −1,26	0,070
Puntos local − visitante por partido	puntos	−0,42	−0,65 a −0,20	0,005	−0,21	−0,42 a −0,004	0,242
Goles local − visitante por partido	goles	−0,24	−0,41 a −0,08	0,018	−0,16	−0,28 a −0,03	0,090
Remates local − visitante por partido	remates	−1,39	−2,28 a −0,50	0,018	−1,71	−2,33 a −1,05	0,005
Amarillas visitante − local por partido	tarjetas	−0,25	−0,38 a −0,11	0,005	−0,18	−0,37 a 0,03	0,328
Faltas visitante − local por partido	faltas	−0,94	−1,39 a −0,52	0,005	−0,12	−0,57 a 0,31	0,801
Prob. implícita del local (Pinnacle)	%	−3,46	−4,69 a −2,13	0,005	−3,33	−4,61 a −2,20	0,005
Brecha observada − implícita (Pinnacle)	pp	−2,89	−6,57 a 0,71	0,242	−1,46	−4,83 a 1,79	0,801

Premier: 407 partidos sin público frente a 2.568 con público; LaLiga: 471 frente a 2.481. IC 95 % por bloques; Holm dentro de cada liga sobre las 10 medidas del contraste principal (incluye las de Bet365, en outputs/tables/covid_contrasts.csv).

Pruebas sobre los confusores. (a) **Placebo:** ninguna de las 352 ventanas con público de 407 partidos produjo en la Premier una caída tan grande como la observada (mínimo placebo −0,27 frente a −0,42), y ninguna de las 309 de LaLiga (−0,19 frente a −0,21); las ventanas se solapan, así que es una comparación descriptiva y no un valor p exacto. (b) **Sustituciones:** con público, cinco cambios no alteraron la ventaja de local (Premier −0,01; LaLiga −0,06), y la caída de la Premier ocurrió en 2020/21, **con tres cambios** (−0,15 frente a 0,41; diferencia −0,56, IC −0,81 a −0,31): la regla no explica el resultado. Sin embargo, en la reanudación de 2019/20, también sin público, la ventaja de local de la Premier fue 0,46 (n = 92; IC 0,10 a 0,81), y con cinco cambios no se observa caída (sin público − con público: 0,06; IC −0,32 a 0,44), aunque esa comparación descansa solo en los 92 partidos de la reanudación. La ausencia de público no produjo el mismo efecto en todo momento. (c) **Dosis:** con aforo mínimo la ventaja de la Premier fue 0,32 (n = 65), más cerca del nivel con público, pero con un IC muy amplio (Figura 4). (d) **Canales:** en la Premier cayeron tanto el canal arbitral (−0,25 amarillas y −0,94 faltas de diferencia) como el deportivo (−1,39 remates); en LaLiga solo el deportivo es claro (−1,71 remates), y su canal arbitral no supera a Holm. Que los canales difieran entre ligas impide sostener un mecanismo común.

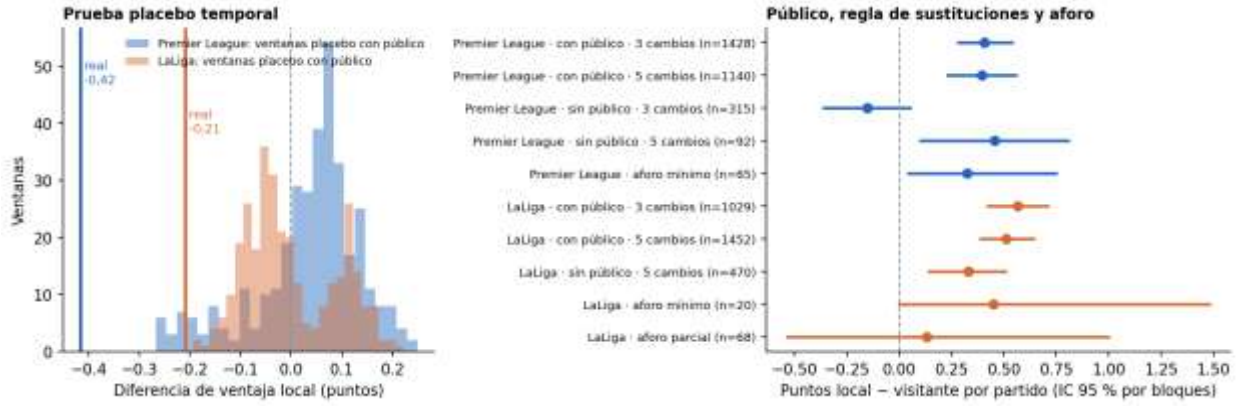


Figura 4. Izquierda: distribución de la diferencia de ventaja local en ventanas placebo con público frente a la diferencia real. Derecha: ventaja de local por público, regla de sustituciones y aforo (IC 95 % por bloques).

Mercado. La probabilidad implícita del local en Pinnacle bajó 3,46 pp en la Premier y 3,33 pp en LaLiga (p de Holm 0,005), lo que es consistente con que las cuotas se ajustaron. En el periodo completo, la brecha observada − implícita fue negativa pero sus IC incluyen cero (Tabla 8). Por

mitades, en la Premier fue de −0,8 pp en la primera mitad y −4,2 pp en la segunda (IC −7,2 a −1,1), es decir, a inicios de 2021 las cuotas todavía sobrevaloraban al local, lo que es compatible con un ajuste incompleto (Winkelmann et al., 2021); la diferencia entre mitades, sin embargo, no es significativa (−3,4; IC −10,0 a 3,5). Los datos no permiten establecer la velocidad ni la eficiencia con que el mercado incorporó el cambio.

6. Discusión

La Tabla 9 separa lo que el estudio muestra en tres niveles de evidencia: lo que se observó, lo que se sostiene inferencialmente y lo que solo puede interpretarse.

Tabla 9. Conclusiones por nivel de evidencia.

Tema	Descriptivo (se observó)	Inferencial (se sostiene)	Interpretación (no demostrada)
Calibración	ECE 2,6–3,0 pp; REL ≈ 0,003–0,004 frente a RES ≈ 0,08	Premier: calibración aceptable según el criterio declarado. LaLiga: ECE compatible con calibración perfecta, pero pendiente no concluyente	Las cuotas de cierre funcionan como buenos pronósticos; no se prueba eficiencia informativa ni económica
FLB y método	Pendientes 0,2 (Premier) y 1,0 (LaLiga) con potencia; 0,6–1,7 con proporcional	El método proporcional añade 0,34–0,66 pp/10 pp (robusto a todo). FLB residual en LaLiga: dirección estable, significancia no robusta	Parte del FLB citado en la literatura podría deberse al método de remoción
Ligas, temporadas, casas	LaLiga − Premier: 0,82 pp/10 pp	Casas equivalentes en RPS. Ligas y temporadas: no concluyente (EMD 2,05)	No se puede afirmar que LaLiga sea menos eficiente
Público local	Premier: de 0,40 a −0,01 puntos; LaLiga: de 0,53 a 0,32	Premier: asociación robusta (ajuste, placebo, errores diádicos, sustituciones). LaLiga: débil	Consistente con un efecto del público vía árbitro y rendimiento, pero no identificado causalmente; la reanudación de 2019/20 no lo replica
Mercado	Implícita del local −3,3 a −3,5 pp	El ajuste es significativo; la brecha y el aprendizaje no	Consistente con actualización de precios; velocidad y eficiencia no establecidas

Significancia frente a relevancia práctica. El efecto del método es estadísticamente muy fuerte pero pequeño para la calidad del pronóstico (el RPS cambia en la cuarta cifra decimal); importa para la inferencia sobre el sesgo. El FLB de LaLiga, en cambio, sería relevante en magnitud (4–11 pp entre extremos), pero con 1.140 partidos no se distingue con seguridad del azar. El margen sí tiene relevancia práctica directa: con 5,5 pp en Bet365 y 2,8 pp en Pinnacle, quien apuesta paga en promedio esa comisión aunque las probabilidades justas estén bien calibradas.

Alcance. Las conclusiones se limitan a dos ligas, dos casas, cuotas de cierre y las temporadas observadas. La caída de la ventaja de local en la Premier (−0,42) es mayor que el promedio de 11 ligas de McCarrick et al. (2021), −0,17, y la de LaLiga es cercana a ese promedio; la reducción de amarillas en la Premier coincide con Bryson et al. (2021).

7. Limitaciones

- **Potencia.** Con 1.140 partidos por liga, el EMD de la pendiente es de 1,4–1,6 pp por 10 pp; efectos menores, como el estimado en LaLiga, no pueden confirmarse ni descartarse. La potencia es menor aún para diferencias entre ligas y temporadas.
- **Especificación.** El método de remoción, el agrupamiento y los umbrales cambian algunos resultados. Se fijó un análisis principal y se reportaron todas las variantes; los márgenes de equivalencia se definieron después de ver las estimaciones.

- **Dependencia.** El bootstrap de bloques captura dependencia temporal, que resultó despreciable; la dependencia por equipos se evaluó con errores diádicos y una prueba de dispersión, pero el estimador diádico es inestable con pocos equipos.
- **Identificación causal.** El periodo sin público coincidió con otros cambios. Las pruebas de placebo, sustituciones y fuerza de los equipos descartan algunos confusores, no todos (calendario, contagios), y la reanudación de 2019/20 muestra heterogeneidad que el diseño no explica. Tampoco hay datos de asistencia por partido.
- **Fuente.** Los datos provienen de un agregador, no de las casas; solo dos operadores y solo cuotas de cierre. La advertencia de Pinnacle impide extender la ventana.
- **Carácter retrospectivo.** Ningún resultado constituye una estrategia o recomendación de apuesta, y una desviación histórica no implica que se repita.

Juego responsable. Las apuestas implican riesgo de pérdida y su valor esperado es negativo por el margen. En Colombia solo los operadores autorizados por Coljuegos pueden ofrecer apuestas en línea, prohibidas para menores de 18 años.

8. Uso de inteligencia artificial

El equipo usó un asistente de IA (Claude, de Anthropic) para programar el análisis en Python, depurar errores, redactar borradores del reporte, la presentación y este informe, buscar y contrastar referencias e implementar los análisis de robustez pedidos en la revisión. La IA trabajó solo con los archivos de Football-Data suministrados por el equipo. Las preguntas, el alcance (ligas, temporadas, casas, método principal, periodos de la pandemia) y las decisiones de esta corrección fueron tomados o aprobados por el equipo.

La verificación se organizó en tres capas: (i) **23 pruebas automáticas**, incluida una que compara el estimador diádico con un cálculo por fuerza bruta; (ii) un **recálculo independiente** (verificacion/verificar_independiente.py) que repite 16 comprobaciones de cifras del informe desde los CSV originales sin usar el código principal, y que coincidió en las 16; y (iii) un **protocolo de verificación humana** (V1–V8: ejecución en un equipo propio, cotejo de tablas, cálculo manual del margen y de k en una hoja de cálculo, revisión de fórmulas, referencias, fechas e interpretación). Que las pruebas pasen demuestra que el código hace lo programado, no que los supuestos estadísticos sean adecuados; por eso la capa (iii) la realizó el equipo el 02/10/2026 (Andrés Beleño, Mauricio Serrano y Carlos Cadena): las ocho verificaciones cumplieron su criterio de aceptación, y el responsable, la fecha y el resultado de cada una están en la bitácora completa del Anexo A.

Bibliografía

Aronow, P. M., Samii, C. y Assenova, V. A. (2015). Cluster-robust variance estimation for dyadic data. *Political Analysis, 23*(4), 564–577.

Bryson, A., Dolton, P., Reade, J. J., Schreyer, D. y Singleton, C. (2021). Causal effects of an absent crowd on performances and refereeing decisions during Covid-19. *Economics Letters, 198*, 109664.

Cameron, A. C. y Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources, 50*(2), 317–372.

Clarke, S., Kovalchik, S. e Ingram, M. (2017). Adjusting bookmaker's odds to allow for overround. *American Journal of Sports Science, 5*(6), 45–49.

Football-Data.co.uk. (s. f.). *Football results, statistics and soccer betting odds data* [Conjunto de datos]. https://www.football-data.co.uk/

Forrest, D., Goddard, J. y Simmons, R. (2005). Odds-setters as forecasters: The case of English football. *International Journal of Forecasting, 21*(3), 551–564.

Goal. (s. f.). *¿Por qué sigue habiendo 5 cambios en los partidos de LaLiga 2021-2022?* https://www.goal.com/es/noticias/por-que-sigue-habiendo-5-cambios-en-los-partidos-de-laliga-2021-2022/144yh95di2xmv1ij8fwaas16mj

Griffith, R. M. (1949). Odds adjustments by American horse-race bettors. *The American Journal of Psychology, 62*(2), 290–294.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science, 8*(4), 355–362.

Levitt, S. D. (2004). Why are gambling markets organised so differently from financial markets? *The Economic Journal, 114*(495), 223–246.

McCarrick, D., Bilalic, M., Neave, N. y Wolfson, S. (2021). Home advantage during the COVID-19 pandemic: Analyses of European football leagues. *Psychology of Sport and Exercise, 56*, 102013.

Murphy, A. H. (1973). A new vector partition of the probability score. *Journal of Applied Meteorology, 12*(4), 595–600.

Patton, A., Politis, D. N. y White, H. (2009). Correction to "Automatic block-length selection for the dependent bootstrap". *Econometric Reviews, 28*(4), 372–375.

Politis, D. N. y White, H. (2004). Automatic block-length selection for the dependent bootstrap. *Econometric Reviews, 23*(1), 53–70.

Shin, H. S. (1991). Optimal betting odds against insider traders. *The Economic Journal, 101*(408), 1179–1185.

Shin, H. S. (1993). Measuring the incidence of insider trading in a market for state-contingent claims. *The Economic Journal, 103*(420), 1141–1153.

Sky Sports. (31 de marzo de 2022). *Premier League to introduce five subs per match from next season*. https://www.skysports.com/football/news/11095/12578904

Snowberg, E. y Wolfers, J. (2010). Explaining the favorite–long shot bias: Is it risk-love or misperceptions? *Journal of Political Economy, 118*(4), 723–746.

Štrumbelj, E. (2014). On determining probability forecasts from betting odds. *International Journal of Forecasting, 30*(4), 934–943.

Winkelmann, D., Deutscher, C. y Ötting, M. (2021). Bookmakers' mispricing of the disappeared home advantage in the German Bundesliga after the COVID-19 break. *Applied Economics, 53*(26), 3054–3064.

Anexo A. Bitácora de uso de IA

Herramienta: Claude (Anthropic), en conversación con el equipo. Cada fila registra la solicitud, el producto de la IA, la verificación técnica disponible y la revisión humana del equipo según el protocolo V1–V8 (verificacion/verificacion_manual.xlsx, hoja «Protocolo», donde está el detalle de cada verificación).

#	Solicitud del equipo	Producto de la IA	Verificación técnica disponible	Revisión del equipo (responsable, fecha, resultado)
1	Limpiar los datos y responder la pregunta principal con el método de potencia	Lectura, validación, margen y cuatro métodos	Pruebas test_local_data y test_methods; recálculo independiente V1–V4 coincide	V1, V5: M. Serrano; V3, V4: A. Beleño · 02/10/2026 · coincide
2	Incorporar los CSV 2017/18–2021/22	Ampliación de la ventana	Huellas SHA-256 (Anexo D); 380 partidos y 20 equipos por temporada	V1: M. Serrano · 02/10/2026 · coincide
3	Presentación de 20 minutos	Archivo .pptx de 26 diapositivas	Cifras tomadas de las tablas del código	V2: A. Beleño · 02/10/2026 · coincide
4	Instrucciones para ejecutar el código en un PC	Pasos de instalación y scripts paso a paso	Ejecución en el PC del equipo (V1)	V1: M. Serrano · 02/10/2026 · coincide
5	Reporte de calibración e inventario de cobertura	inventory.py, report.py, tablas de cobertura y desviaciones	Prueba test_results; inventario contrastado con coverage.csv	V2: A. Beleño · 02/10/2026 · coincide
6	Búsqueda de literatura	Referencias de la bibliografía	Contrastadas con la página del editor	V6: A. Beleño · 02/10/2026 · coincide
7	Corregir el informe según el dictamen del director	robustness.py, figuras, pruebas, verificación independiente e informe corregido	23 pruebas (incluye el estimador diádico frente a fuerza bruta); recálculo independiente 16/16	V1, V5: M. Serrano; V2, V3, V4, V6, V8: A. Beleño; V7: C. Cadena · 02/10/2026 · coincide

Errores de la IA detectados y corregidos: variable sombreada en una prueba en R; un f-string incompatible con Python 3.11; cuantiles con valores faltantes; reemplazo de comas en el inventario; en la revisión, el intervalo bootstrap del ECE resultó sesgado hacia arriba (no se reporta) y el bootstrap multiplicativo por equipos sobrestimaba la varianza por construcción, por lo que se sustituyó por errores diádicos analíticos.

Anexo B. Familias de hipótesis y corrección de Holm

Inventario completo: 988 hipótesis en 50 familias (outputs/tables/inventario_hipotesis.csv, con p crudo y ajustado de cada una; resumen en familias_holm.csv). Rol: P = pregunta principal; S = secundarias; E = exploratoria; R = sensibilidad.

Familia	Rol	Hipótesis	p mínimo	p < 0,05	Holm < 0,05
P1 · Pendiente del error (2022/23–2024/25)	Principal	16	0,006	4	0
E · Pendiente por temporada	Exploratoria	48	0,021	2	0
P2 · Contraste de extremos 20/60	Principal (complementaria)	16	0,020	3	0
E · Contraste de extremos por temporada	Exploratoria	48	0,057	0	0
P3 · Método − proporcional (pendiente)	Principal (sensibilidad al método)	12	0,000	12	12
P3 · Método − proporcional (extremos)	Principal (sensibilidad al método)	12	0,000	12	12
E · Método − proporcional por temporada	Exploratoria	72	0,000	72	72
S1c · Pinnacle − Bet365 (RPS)	Secundaria (casas)	8	0,231	0	0
S1c · Pinnacle − Bet365 (pendiente)	Secundaria (casas)	8	0,000	4	2
S1c · Pinnacle − Bet365 (margen)	Secundaria (casas)	2	0,000	2	2
E · Casas por temporada	Exploratoria	54	0,000	18	15
S1 · LaLiga − Premier (pendiente)	Secundaria 1 (ligas)	8	0,263	0	0
S1 · LaLiga − Premier (extremos)	Secundaria 1 (ligas)	8	0,166	0	0
S1 · LaLiga − Premier (RPSS)	Secundaria 1 (ligas)	8	0,333	0	0
E · Ligas por temporada	Exploratoria	72	0,205	0	0
S2 · Temporadas consecutivas (pendiente)	Secundaria 2 (temporadas)	32	0,117	0	0
S2 · Temporadas consecutivas (extremos)	Secundaria 2 (temporadas)	32	0,280	0	0

Familia	Rol	Hipótesis	p mínimo	p < 0,05	Holm < 0,05
S2 · Temporadas consecutivas (RPSS)	Secundaria 2 (temporadas)	32	0,047	5	0
R · Umbrales del contraste (15/65)	Sensibilidad	16	0,000	8	5
R · Umbrales del contraste (20/60 propios del método)	Sensibilidad	16	0,020	3	0
R · Pendiente con bloque 1	Sensibilidad	16	0,001	7	1
R · Pendiente con bloque 10	Sensibilidad	16	0,005	4	0
R · Pendiente con bloque 40	Sensibilidad	16	0,005	4	0
R · Pendiente con bloque 20	Sensibilidad	16	0,006	4	0
S3 · Premier · sin público (incl. aforo mínimo) − con público	Sensibilidad	10	0,000	8	8
S3 · Premier · sin público − después	Secundaria 3 · complementaria	10	0,000	8	7
S3 · Premier · sin público − antes	Secundaria 3 · complementaria	10	0,000	8	8
S3 · Premier · sin público − con público	Secundaria 3 (público local)	10	0,000	8	8
S3 · Premier · después − antes	Secundaria 3 · complementaria	10	0,183	0	0
S3 · LaLiga · sin público (incl. aforo mínimo) − con público	Sensibilidad	10	0,000	6	3
S3 · LaLiga · sin público − después	Secundaria 3 · complementaria	10	0,000	5	3
S3 · LaLiga · sin público − antes	Secundaria 3 · complementaria	10	0,000	6	3
S3 · LaLiga · sin público − con público	Secundaria 3 (público local)	10	0,000	6	3
S3 · LaLiga · después − antes	Secundaria 3 · complementaria	10	0,004	1	1
S3 · Ajustado por fuerza	Secundaria 3 (público local)	6	0,000	4	3
S3 · Premier − LaLiga	Secundaria 3 (público local)	10	0,011	1	0
R · Matriz de 25 umbrales · Premier · B365 · power	Sensibilidad	25	0,460	0	0
R · Matriz de 25 umbrales · Premier · B365 · proportional	Sensibilidad	25	0,067	0	0
R · Matriz de 25 umbrales · Premier · PS · power	Sensibilidad	25	0,481	0	0
R · Matriz de 25 umbrales · Premier · PS · proportional	Sensibilidad	25	0,200	0	0
R · Matriz de 25 umbrales · LaLiga · B365 · power	Sensibilidad	25	0,002	9	0
R · Matriz de 25 umbrales · LaLiga · B365 · proportional	Sensibilidad	25	0,000	25	7
R · Matriz de 25 umbrales · LaLiga · PS · power	Sensibilidad	25	0,013	7	0
R · Matriz de 25 umbrales · LaLiga · PS · proportional	Sensibilidad	25	0,001	21	1
R · Potencia − otros métodos (log_loss)	Sensibilidad	12	0,022	1	0
R · Potencia − otros métodos (RPS)	Sensibilidad	12	0,008	4	0
R · ECE frente a calibración perfecta (5 grupos)	Principal (diagnóstico)	16	0,169	0	0
R · ECE frente a calibración perfecta (10 grupos)	Principal (diagnóstico)	16	0,419	0	0
R · ECE frente a calibración perfecta (15 grupos)	Principal (diagnóstico)	16	0,160	0	0
R · ECE frente a calibración perfecta (20 grupos)	Principal (diagnóstico)	16	0,464	0	0

Anexo C. Robustez de la inferencia

Tabla C1. IC 95 % según el esquema de remuestreo (método de potencia).

Estadístico	Grupo	Independiente	Bloques 10	Bloques 20	Bloques 40	Semanas
Pendiente del error (pp/10 pp)	LaLiga · Bet365	−0,02 a 2,00	−0,04 a 2,06	−0,05 a 2,11	−0,07 a 2,09	−0,10 a 2,03
Pendiente del error (pp/10 pp)	Premier League · Bet365	−0,78 a 1,14	−0,82 a 1,09	−0,80 a 1,05	−0,69 a 1,03	−0,82 a 1,06
Contraste de extremos (pp)	LaLiga · Bet365	−1,26 a 11,79	−1,96 a 12,58	−2,01 a 12,63	−1,41 a 12,18	−2,15 a 12,26
Contraste de extremos (pp)	Premier League · Bet365	−6,99 a 5,96	−7,17 a 5,66	−6,93 a 5,04	−6,21 a 4,49	−8,12 a 6,16
Pendiente LaLiga − Premier	LaLiga − Premier · Bet365	−0,58 a 2,21	−0,53 a 2,25	−0,53 a 2,33	−0,56 a 2,20	−0,56 a 2,27

Tabla C2. Efecto mínimo detectable (80 % de potencia, α = 0,05) con el mayor error estándar entre esquemas.

Estadístico	Grupo	Estimación	EE máximo	EMD	EMD con Holm
Contraste de extremos (pp)	Premier League · Bet365	−0,67	3,52	9,85	13,35
Contraste de extremos (pp)	Premier League · Pinnacle	−0,05	3,36	9,43	12,77
Contraste de extremos (pp)	LaLiga · Bet365	5,29	3,76	10,52	14,26
Contraste de extremos (pp)	LaLiga · Pinnacle	6,65	3,73	10,44	14,14

Estadístico	Grupo	Estimación	EE máximo	EMD	EMD con Holm
Pendiente LaLiga − Premier	LaLiga − Premier · Bet365	0,82	0,73	2,05	2,62
Pendiente LaLiga − Premier	LaLiga − Premier · Pinnacle	0,80	0,74	2,06	2,63
Pendiente del error (pp/10 pp)	Premier League · Bet365	0,18	0,49	1,37	1,85
Pendiente del error (pp/10 pp)	Premier League · Pinnacle	0,22	0,49	1,37	1,86
Pendiente del error (pp/10 pp)	LaLiga · Bet365	1,00	0,55	1,55	2,11
Pendiente del error (pp/10 pp)	LaLiga · Pinnacle	1,02	0,56	1,57	2,13
Potencia − proporcional (pp/10 pp)	Premier League · Bet365	−0,62	0,03	0,08	0,11
Potencia − proporcional (pp/10 pp)	Premier League · Pinnacle	−0,34	0,02	0,05	0,06
Potencia − proporcional (pp/10 pp)	LaLiga · Bet365	−0,66	0,03	0,09	0,12
Potencia − proporcional (pp/10 pp)	LaLiga · Pinnacle	−0,36	0,02	0,05	0,07
RPS Pinnacle − Bet365	Premier League	0,0001	0,0002	0,0005	0,0006
RPS Pinnacle − Bet365	LaLiga	0,0001	0,0002	0,0004	0,0006



Figura C1. Izquierda: autocorrelación media de las contribuciones de cada partido a la pendiente y al RPS. Derecha: error estándar de cada esquema relativo al de bloques de 20.

Anexo D. Reproducibilidad

El código, los datos, las tablas y las figuras se entregan junto con este informe (carpeta betting-calibration). Entorno de la ejecución entregada: Python 3.11.15, numpy 2.4.4, pandas 3.0.2, scipy 1.17.1, matplotlib 3.10.9 (requirements-lock.txt y outputs/run_metadata.json). Ejecución completa: python run_all.py (≈ 2 min); paso a paso: pasos/paso1_datos.py a pasos/paso6_robustez.py; pruebas: python -m unittest discover -s tests -v; verificación independiente: python verificacion/verificar_independiente.py. Parámetros en config.json (método principal, temporadas, fechas de periodos, bloque 20, 2.000 réplicas, semilla 20261001).

Tabla D1. Archivos de datos y huellas SHA-256 (primeros 16 caracteres; completas en data/source_snapshot.csv y data/covid_source_manifest.csv).

Archivo	Bytes	SHA-256
E0_2022-23.csv	176180	8442792d3b614c94…
E0_2023-24.csv	172196	b2e057b0ed959f19…
E0_2024-25.csv	197110	d0c8ce4a96d886cf…
SP1_2022-23.csv	172199	53348112526b5165…
SP1_2023-24.csv	168164	5323f596c7ed318e…
SP1_2024-25.csv	192863	c086e96d6a53f6e6…
E0_2017-18.csv	100734	4f3389365ef3f7ac…
E0_2018-19.csv	96144	7c096b3c2ecd54c6…
E0_2019-20.csv	175475	100037618b94f940…

Archivo	Bytes	SHA-256
E0_2020-21.csv	175815	5afe63f69401457b…
E0_2021-22.csv	175363	335afcbabeb2939f…
SP1_2017-18.csv	96801	5786719e06d1a538…
SP1_2018-19.csv	92914	9b8cece2c85e90e3…
SP1_2019-20.csv	171484	a05d5d60eee0b141…
SP1_2020-21.csv	171721	b4137db923101f46…
SP1_2021-22.csv	172174	2d9e619700712823…

Código esencial (src/methods.py y src/inference.py, extracto):

```
def remove_margin(odds):
    p = 1 / odds; S = p.sum(axis=1)                    # probabilidades brutas y suma
    additive = p - (S[:, None] - 1) / 3
    for i, row in enumerate(p):
        k[i] = brentq(lambda x: np.sum(row**x) - 1, 1, upper)   # potencia: Σ p^k = 1
        power[i] = row**k[i]
        q = lambda x: 2*row**2/S[i] / (np.sqrt(x*x + 4*(1-x)*row**2/S[i]) + x)
        z[i] = brentq(lambda x: q(x).sum() - 1, 0, 1 - 1e-10)   # Shin: Σ q(z) = 1
    return {"proportional": p/S[:, None], "power": power, "additive": additive, "shin": shin}


def block_weights(n, strata, reps, block, seed):          # bootstrap circular de bloques
    for ids in strata:                                    # cada liga–temporada por separado
        starts = rng.integers(0, size, size=(reps, ceil(size/block)))
        draws = (starts[:, :, None] + np.arange(block)) % size   # bloques circulares
        W[b, ids] = np.bincount(draws[b][:size], minlength=size) # peso de cada partido completo


def error_slope(q, y, W):   # pendiente de 100(y − q) sobre 10q, ponderada por réplica
    x = 10*q; e = 100*(y - q)
    return (W@(x*e).sum(1) - W@x.sum(1)*W@e.sum(1)/s0) / (W@(x*x).sum(1) - (W@x.sum(1))**2/s0)
```